

Analyse de données, Reporting et Dataviz

Compétence 2 - Traiter les données

Thématique du projet

Analyse du trafic aérien au départ des aéroports de New York en 2023

• **Contexte.** En tant que **Data Analyst Team**, vous avez décroché un contrat auprès du consortium composé des trois plus importants aéroports de New York :

- **John Fitzgerald Kennedy International Airport (JFK)**
- **LaGuardia Airport (LGA)**
- **Newark Liberty International Airport (EWR)**



L'objet de contrat porte sur l'étude statistique de deux thématiques d'intérêt sur l'année 2023 :

- Les retards des avions au départ de New York et/ou à l'arrivée de leur destination
- Les annulations de vols

En particulier, la direction du consortium des trois aéroports souhaite qu'on lui apporte une réponse fiable et rigoureuse à plusieurs questions d'intérêt qui sont listées dans les deux sections suivantes. A chacune des questions, l'équipe de **Data Analyst** devra fournir un graphique accompagné le cas échéant d'un indicateur d'association et fournir une interprétation en lien avec le contexte.



Afin de répondre aux diverses questions, vous avez à votre disposition un fichier de données nommé

`nycflights2023.txt`

contenant l'ensemble des informations utiles. Ce fichier de données contient notamment 435 332 observations correspondant à autant de vols prévus sur les trois aéroports en 2023 sur lesquels 21 variables ont été observées (cf. Annexe 1 pour un descriptif). Parmi ces vols, certains ont été purement et simplement annulés. Ces vols annulés se distinguent des autres vols par des valeurs manquantes simultanément sur les trois variables suivantes : heure de départ, heure d'arrivée et durée de vol.

La réalisation de ce projet se fera uniquement à l'aide du langage de programmation **R base** (aucune librairie nécessaire à installer) et avec le logiciel **RStudio**.

Phase préliminaire

Avant de se lancer dans l'analyse des données, il convient comme pour toute étude statistique de réaliser quelques étapes préliminaires. Dans ce but, je vous invite à suivre les étapes suivantes :

1. Créer sur votre espace de travail un dossier nommé **Flights2023**, puis les sous-dossiers **Data** et **RStudio**.
2. Importer depuis E-Campus le fichier de données, puis l'enregistrer dans le sous-dossier **Data**.
3. Ouvrir le logiciel **RStudio**, puis y créer un projet en choisissant le sous-dossier **RStudio** comme dossier de travail par défaut.
4. Créer un script, puis y ajouter un en-tête avec au minimum les informations suivantes : thématique, auteurs, date de création et source des informations.
5. Les jeux de données d'origine anglo-saxonne présentent souvent des variables quantitatives dont les unités ne sont pas similaires aux nôtres, pouvant rendre l'interprétation contextuelle délicate. Dans le cas présent, la distance entre deux aéroports s'exprime en **miles** qui n'est pas une unité de mesure usuelle en Europe tout comme la variable **dewp** exprimée en Fahrenheit. Opérer une transformation sur chacune des variables quantitatives concernées par ce phénomène afin de proposer des valeurs en accord avec les unités traditionnelles en France.
6. Un jeu de données ne contient pas forcément toutes les variables pertinentes au départ. Il arrive souvent que l'on soit amené à créer une ou plusieurs variables d'intérêt à partir des variables existantes. Dans le cas présent, je vous invite à créer les variables suivantes :
 - **delay_dep** : variable qualitative binaire qui prendra la modalité "Yes" si un retard au décollage est observé et "No" dans le cas contraire.
 - **delay_arr** : variable qualitative binaire qui prendra la modalité "Yes" si un retard à l'atterrissage est observé et "No" dans le cas contraire.
 - **canceled** : variable qualitative binaire qui prendra la modalité "Yes" si le vol a été annulé et "No" sinon.
 - **distance_class** : variable qualitative ordinale obtenue par discrétisation de la variable **distance** en 5 classes de même fréquence d'observations (20% dans le cas présent) via la fonction `cut()`.
 - **dewp_class** : variable qualitative ordinale obtenue par discrétisation de la variable **dewp** en 4 classes de même fréquence d'observations (25% dans le cas présent) via la fonction `cut()`.
7. Enfin, il faudra s'assurer que chacune des variables du jeu de données présente un type de variable cohérent avec son type intrinsèque en faisant usage des fonctions `as.numeric()`, `as.factor()`, etc.

```
$ dep_time      : int [1:435352] 1 18 31 33 36 503 520 524 537 547 ...
$ sched_dep_time: int [1:435352] 2038 2300 2344 2140 2048 500 510 530 520 545 ...
$ dep_delay     : num [1:435352] 203 78 47 173 228 3 10 -6 17 2 ...
$ arr_time      : int [1:435352] 328 228 500 238 223 808 948 645 926 845 ...
$ sched_arr_time: int [1:435352] 3 135 426 2352 2252 815 949 710 818 852 ...
$ arr_delay     : num [1:435352] 205 53 34 166 211 -7 -1 -25 68 -7 ...
$ carrier       : Factor w/ 14 levels "9E","AA","AS",...: 12 5 4 4 12 2 4 2 12 10 ...
$ origin        : Factor w/ 3 levels "EWR","JFK","LGA": 1 2 2 2 1 1 2 1 1 1 ...
$ dest          : Factor w/ 118 levels "ABQ","ACK","AGS",...: 107 6 16 24 35 64 16 77 48 38 ...
$ air_time      : num [1:435352] 367 108 190 108 80 154 192 119 258 157 ...
$ distance      : num [1:435352] 2500 760 1576 636 488 ...
$ temp          : num [1:435352] 13.89 8.33 8.33 11.11 13.89 ...
$ dewp          : num [1:435352] 0.556 3.333 3.333 0.556 0.556 ...
$ humid         : num [1:435352] 40.3 70.7 70.7 48.3 40.3 ...
$ wind_dir      : num [1:435352] 290 0 0 270 290 130 0 130 130 130 ...
$ wind_speed    : num [1:435352] 16.7 0 0 13 16.7 ...
$ wind_gust     : num [1:435352] 19.2 0 0 14.9 19.2 ...
$ precip        : num [1:435352] 0 0 0 0 0 0.000254 0.000254 0.000254 0.000254 ...
$ pressure      : num [1:435352] 1014 1016 1016 1015 1014 ...
$ visib         : num [1:435352] 16.1 16.1 16.1 16.1 16.1 ...
$ name          : Factor w/ 14 levels "Alaska Airlines Inc.",...: 14 4 9 9 14 3 9 3 14 13 ...
$ canceled      : Factor w/ 2 levels "No","Yes": 1 1 1 1 1 1 1 1 1 1 ...
$ delay_dep     : Factor w/ 2 levels "No","Yes": 2 2 2 2 2 2 2 1 2 2 ...
$ delay_arr     : Factor w/ 2 levels "No","Yes": 2 2 2 2 2 1 1 1 2 1 ...
$ distance      : num [1:435352] 4023 1223 2536 1024 785 ...
$ distance_class: Factor w/ 5 levels "[80, 405)","[405, 718)",...: 5 3 5 2 2 4 5 3 4 4 ...
$ dewp_class    : Factor w/ 4 levels "[-27.22, -1.111)",...: 2 2 2 2 2 3 3 3 3 3 ...
```

Thématique 1 : retard des avions

L'objectif dans cette section va consister à apporter une réponse à chacune des questions ci-dessous en produisant à chaque fois un graphique permettant d'apporter des éléments factuels, en proposant si nécessaire un indicateur d'association et en rédigeant systématiquement une analyse contextuelle basée sur le graphique et le cas échéant l'indicateur associés.

1. **Quel aéroport a connu le plus de vols retardés en 2023 ?**

Conseil. Proposer un diagramme de Pareto exprimé en effectifs en affichant en rouge le mode de la distribution.

2. **La proportion de vols présentant un retard au décollage est-elle similaire sur les trois aéroports durant l'année 2023 ?**

Conseil. Proposer un diagramme à barres empilées (présence d'un retard vs absence d'un retard) selon l'aéroport. Proposer un indicateur d'association approprié.

3. **Le temps de retard au décollage est-il différent d'un aéroport à l'autre ?**

Conseil. Ne pas hésiter à appliquer une transformation logarithmique à la variable d'intérêt pour mieux visualiser les éventuelles différences entre les aéroports. Proposer un indicateur d'association approprié.

4. **Un retard au décollage est-il systématiquement synonyme d'un retard à l'atterrissage ?**

Conseil. Proposer un diagramme à barres empilées (présence d'un retard à l'atterrissage vs absence d'un retard à l'atterrissage) selon la présence ou l'absence d'un retard au décollage. Proposer un indicateur d'association approprié.

5. **Le délais de retard à l'atterrissage s'explique-t-il par le délais de retard au décollage ?**

Conseil. Représenter un diagramme permettant de visualiser le délais à l'atterrissage en fonction du délais au décollage. Etudier le type éventuel d'association, puis proposer un modèle de régression linéaire simple avec une interprétation des indicateurs et des paramètres pertinents.

6. **Quelles sont les compagnies les plus fiables au décollage pour l'aéroport JFK ?**

Conseil. Proposer un diagramme de Pareto pour présenter un top 5 des compagnies aériennes. On indiquera en rouge le mode de la distribution et en orange les deux compagnies dont la fréquence absolue de fiabilité vient immédiatement derrière le mode.

7. **Quel jour de la semaine observe-t-on le plus de retard au décollage sur l'aéroport JFK ?**

Conseil. Représenter en rouge le mode de la distribution sur le diagramme afin de le mettre en évidence.

8. **Existe-t-il une incidence de l'horaire de départ sur la présence d'un retard au décollage ?**

Conseil. Proposer un diagramme à barres empilées (présence d'un retard vs absence d'un retard) selon la classe de l'horaire de départ exprimé sous la forme de trois modalités : 6h - 14h, 14h - 22h et 22h - 6h ; en s'assurant que les classes sont disjointes.

9. **Existe-t-il une association entre la durée de retard au départ et la durée de retard à l'arrivée ? Si oui, cette association est-elle linéaire ou non-linéaire ? Proposer dans le premier cas un modèle de régression simple avec une interprétation des indicateurs et paramètres d'intérêt.**

Conseil. Proposer un diagramme judicieux avec une régression lissée, puis proposer un modèle de régression linéaire dont on jugera de la qualité avant une éventuelle interprétation contextuelle.

Thématique 2 : annulation des vols

L'objectif dans cette section va consister à apporter une réponse à chacune des questions ci-dessous en produisant à chaque fois un graphique permettant d'apporter des éléments factuels, en proposant si nécessaire un indicateur d'association et en rédigeant systématiquement une analyse contextuelle basée sur le graphique et le cas échéant l'indicateur associé.

1. Quel aéroport a connu le plus d'annulation de vols en 2013 ?

Conseil. Réaliser un diagramme de Pareto en effectifs pour mettre en évidence le classement des aéroports selon le nombre de vols annulés. On indiquera en rouge le mode de la distribution.

2. La proportion de vols annulés est-elle similaire d'un aéroport à l'autre ?

Conseil. Réaliser un diagramme à barres empilées représentant la distribution de la variable `canceled` selon l'aéroport. Proposer un indicateur d'association approprié.

3. Quelles sont les compagnies aériennes qui ont subi le plus d'annulation de vols en 2023 tout aéroport confondu ?

Conseil. Réaliser un diagramme de Pareto permettant d'éditer le top 10 des compagnies présentant le plus d'annulation de vols exprimé en effectifs. On indiquera en rouge le mode de la distribution et en orange les deux compagnies dont la fréquence absolue d'annulation vient immédiatement derrière le mode.

4. L'annulation d'un vol peut-elle s'expliquer par la distance à parcourir pour ce vol ?

Conseil. Réaliser une discrétisation de la variable `distance` en 5 classes contenant 20% d'observations chacune à l'aide de la fonction `cut()`, puis réaliser un diagramme à barres empilées permettant de visualiser la distribution de la variable `canceled` par classe de distance. Proposer un indicateur d'association approprié.

5. L'annulation d'un vol peut-elle s'expliquer par la valeur du point de rosée sur le tarmac ?

Conseil. Réaliser une discrétisation de la variable `dewp` en 4 classes contenant respectivement 25% des observations, puis construire un diagramme permettant de visualiser la distribution de la variable `canceled` par classe de point de rosée. Proposer un indicateur d'association approprié.

Attendus. Ce projet réalisé par groupe de 5 étudiants maximum devra amener aux documents suivants :

- @ Un script en langage **R** pour chacune des parties, scripts qui devront être correctement présentés et documentés ;
- @ Un rapport de 12 pages maximum (hors page de couverture, sommaire et annexes) en PDF et réalisé avec Latex afin de présenter les réponses aux questions posées par la direction. Les illustrations devront être d'une qualité irréprochable et référencées afin de les citer pour simplifier la lecture du document. Enfin, aucune mention du code **R** ne devra être présente dans le document car le rapport est destiné à un responsable et non un technicien ;
- @ Une présentation réalisée sous **Marp** respectant la structure académique proposée et sans aucune mention au langage de programmation **R**.

Note. La date de rendus des documents ainsi que le format seront communiqués directement sur la plateforme E-Campus de l'Université de Caen Normandie.

Annexe 1

Liste des variables disponibles initialement dans le fichier de données :

- dep_time: Actual departure time (UTC)
- sched_dep_time: Schedules departure time (UTC)
- dep_delay: Departure delays in minutes
- arr_time: Actual arrival time (UTC)
- sched_arr_time: Scheduled arrival time (UTC)
- arr_delay: Arrival delays in minutes
- carrier: Two letter carrier abbreviation
- origin: Origine airport
- dest: Destination airport
- air_time: Amount of time spent in the air in minutes
- distance: Distance between airports in miles
- temp: Temperature in F
- dewp: dewpoint in F
- humid: Relative humidity
- wind_dir: Wind direction in degrees
- wind_speed: Wind speed in mph
- wind_gust: Wind gust speed in mph
- precip: Precipitation in inches
- pressure: Sea level pressure in millibars
- visib: Visibility in miles
- name: Complete name of carrier

```
tibble [435,352 × 21] (S3: tbl_df/tbl/data.frame)
 $ dep_time      : int [1:435352] 1 18 31 33 36 503 520 524 537 547 ...
 $ sched_dep_time: int [1:435352] 2038 2300 2344 2140 2048 500 510 530 520 545 ...
 $ dep_delay     : num [1:435352] 203 78 47 173 228 3 10 -6 17 2 ...
 $ arr_time      : int [1:435352] 328 228 500 238 223 808 948 645 926 845 ...
 $ sched_arr_time: int [1:435352] 3 135 426 2352 2252 815 949 710 818 852 ...
 $ arr_delay     : num [1:435352] 205 53 34 166 211 -7 -1 -25 68 -7 ...
 $ carrier       : Factor w/ 14 levels "9E","AA","AS",...: 12 5 4 4 12 2 4 2 12 10 ...
 $ origin        : Factor w/ 3 levels "EWR","JFK","LGA": 1 2 2 2 1 1 2 1 1 1 ...
 $ dest          : Factor w/ 118 levels "ABQ","ACK","AGS",...: 107 6 16 24 35 64 16 77 48 38 ...
 $ air_time      : num [1:435352] 367 108 190 108 80 154 192 119 258 157 ...
 $ distance      : num [1:435352] 2500 760 1576 636 488 ...
 $ temp          : num [1:435352] 57 47 47 52 57 53 48 53 53 53 ...
 $ dewp          : num [1:435352] 33 38 38 33 33 51 48 51 51 51 ...
 $ humid         : num [1:435352] 40.3 70.7 70.7 48.3 40.3 ...
 $ wind_dir      : num [1:435352] 290 0 0 270 290 130 0 130 130 130 ...
 $ wind_speed    : num [1:435352] 10.36 0 0 8.06 10.36 ...
 $ wind_gust     : num [1:435352] 11.92 0 0 9.27 11.92 ...
 $ precip        : num [1:435352] 0e+00 0e+00 0e+00 0e+00 0e+00 1e-04 1e-04 1e-04 1e-04 1e-04 ...
 $ pressure      : num [1:435352] 1014 1016 1016 1015 1014 ...
 $ visib         : num [1:435352] 10 10 10 10 10 4 0.75 4 4 4 ...
 $ name          : Factor w/ 14 levels "Alaska Airlines Inc.",...: 14 4 9 9 14 3 9 3 14 13 ...
```